

New API 傻瓜式使用指南

本指南只讲在网页上怎么点、每个字段填什么、每个数字是什么意思，不讲代码和实现原理。按顺序读完第 1～6 章，你就能把一套自己的 AI API 网关配起来并正常收费、监控。

目录

目录

第 0 章 这个系统是干什么的

三个概念是怎么串起来的

一次 API 请求都经过了什么

第 1 章 装起来 + 第一次登录

1.1 三种安装方式（推荐第 1 种）

1.2 你至少要知道的环境变量

1.3 第一次打开浏览器

1.4 登录后的 3 件必做事

第 2 章 界面速览：菜单在哪、谁能看到什么

2.0 全站页面地图

2.1 侧边栏菜单地图

2.2 顶栏元素

2.3 侧边栏能自定义

第 3 章 接入多渠道大模型（渠道管理）

3.0 渠道页能干什么（功能全景）

3.1 五分钟接入第一个渠道（以 OpenAI 为例）

3.2 渠道列表每一列什么意思

想直接看图的话，这几张最有用：

想搞懂	看哪张图
渠道 / 分组 / 令牌怎么串起来	第 0 章 三个概念是怎么串起来的
一次 API 请求经过哪些环节	第 0 章 一次 API 请求都经过了什么
全站有哪些页面、谁能看	2.0 全站页面地图
三种角色分别能干什么	6.1 三种角色能干什么
渠道页有哪些功能	3.0 渠道页能干什么
多渠道怎么挑、挂了怎么切	3.9 多渠道是怎么挑的、挂了怎么切
一次扣费按哪个价格算	4.1 一次扣费到底按哪个价格算
想看某个数据该去哪个页面	8.0 我想看某个东西，该去哪个页面
系统设置的完整结构	9.0 系统设置总览与保存规则

哪个设置依赖哪个设置	9.8 跨分区依赖清单
上线要按什么顺序做	附录 A 上线全流程一图流

第 0 章 这个系统是干什么的

一句话：它把 OpenAI、Claude、Gemini、Azure、AWS、豆包、通义、DeepSeek 等 **40 多家上游大模型**，统一成一个 OpenAI 兼容的接口对外提供，同时帮你做**用户管理、额度扣费、限流、日志和监控**。


三个角色你要先分清：

角色	在系统里叫什么	干什么
你（站长）	Root / 超级管理员	配渠道、定价格、管人、改系统设置
帮手	Admin / 管理员	帮你管渠道、用户、日志，但改不了细粒度权限，也看不到系统信息/任务插件
客户	User / 普通用户	充值、建 API Key、查自己的用量

三个核心概念（后面反复出现，务必记住）：


- **渠道（Channel）**：一个上游账号 = 一个渠道。你把上游的 API Key 填进来，系统才有"货"可卖。
- **令牌 / API Key（Token）**：客户拿去调用的 sk-xxxxxx。它属于某个用户，可以单独限额、限模型、限 IP。
- **分组（Group）**：连接前两者的桥梁。渠道声明"我服务哪些分组"，令牌声明"我属于哪个分组"，**分组还决定价格倍率**。不同分组 = 不同线路 + 不同价格。


三个概念是怎么串起来的



读法：sk-bbb 属于 vip 分组 → 只会命中声明了 vip 的渠道 A 和 C → 按 vip 的 0.8 倍率计费。

一次 API 请求都经过了什么





前半段（校验、限流）在**令牌**里配，中段（挑渠道、重试、禁用）在**渠道**和**路由可靠性**里配，后段（价格、倍率）在**模型定价**和**分组定价**里配。这三块分别对应第 5、3、4 章。

第 1 章 装起来 + 第一次登录

1.1 三种安装方式（推荐第 1 种）

方式 1：Docker Compose（推荐）

代码块

```
1 git clone https://github.com/QuantumNous/new-api.git
2 cd new-api
3 nano docker-compose.yml    # 改端口、数据库、时区
4 docker-compose up -d
```

方式 2：docker run

代码块

```
1 # 最简：用内置 SQLite
2 docker run --name new-api -d --restart always \
3   -p 3000:3000 \
4   -e TZ=Asia/Shanghai \
5   -v ./data:/data \
6   calciumion/new-api:latest
7
8 # 生产：用 MySQL
9 docker run --name new-api -d --restart always \
10  -p 3000:3000 \
11  -e SQL_DSN="root:密码@tcp(数据库地址:3306)/oneapi" \
12  -e TZ=Asia/Shanghai \
13  -v ./data:/data \
14  calciumion/new-api:latest
```

方式 3：宝塔面板（≥ 9.2.0）→ 应用商店搜 New-API → 一键安装。


⚠ 用 SQLite 时，**-v ./data:/data** 这个挂载不能省，否则容器一重建数据就全丢了。

1.2 你至少要知道的环境变量

变量	作用	默认
PORT	服务端口	3000
TZ	时区，国内填 Asia/Shanghai	—
SQL_DSN	数据库连接串。不填就用 SQLite	—
REDIS_CONN_STRING	Redis 连接串， 生产强烈建议配	—
SESSION_SECRET	登录签名密钥。 多机部署所有节点必须填一样的	—
CRYPTO_SECRET	缓存键密钥。 共用同一个 Redis 的节点必须填一样的	跟随 SESSION_SECRET
SYNC_FREQUENCY	与数据库同步/缓存过期频率（秒）	60
MEMORY_CACHE_ENABLED	内存缓存开关（没有 Redis 时用）	—
STREAMING_TIMEOUT	流式请求多久没响应就断（秒）	300
RELAY_TIMEOUT	所有请求总超时（秒），0 表示不限	0
MAX_REQUEST_BODY_MB	请求体上限（解压后），超了返回 413	32
SESSION_COOKIE_SECURE	上了 HTTPS 就设 true	false
SESSION_COOKIE_TRUSTED_URL	上一项为 true 时 必填 ，逗号分隔的精确 HTTPS Origin	—
TRUSTED_PROXIES	反向代理 IP/CIDR，none 为严格模式	回环 + 内网段
ERROR_LOG_ENABLED	是否记录错误日志	false

多机部署最容易踩的坑：**SESSION_SECRET 不一致 → 用户莫名 401。**

1.3 第一次打开浏览器



访问 http://你的服务器:3000，会遇到两种情况：

情况 A：进入 /setup 初始化向导（4 步）

1. 数据库检查 — 只是给你看识别到的是 SQLite / MySQL / PostgreSQL，顺带提醒你做持久化和备份。直接下一步。

2. 管理员账户 — 填 3 项：

- 管理员用户名
- 密码（至少 8 位）
- 确认密码

(如果提示"管理员账户已初始化"，说明 root 已存在，这一步没有表单，直接下一步)

3. 使用模式 — 三选一：

- 对外运营（默认）：多用户、带计费 and 额度控制
- 个人使用：单人自用，会隐藏定价/计费相关入口
- 演示站点：受限的演示模式

4. 审核并初始化 — 核对后点完成，约 1 秒后自动跳到首页。

情况 B：直接看到登录页（说明是老版本升级或跳过了向导） 默认账号是 **root / 123456**，登录后**第一件事就是改密码**（个人资料 → 安全 → 更改密码）。


1.4 登录后的 3 件必做事

1. 系统设置 → 站点与品牌 → 系统信息 → 服务器地址：填上你的对外访问地址（如 <https://api.yourdomain.com>）。这个值决定了 OAuth 回调地址、支付回调、异步任务媒体地址，**不填后面全是坑**。
2. 系统设置 → 站点与品牌 → 系统信息 → 系统名称：改成你的站名。
3. 去下一章配第一个渠道。

第 2 章 界面速览：菜单在哪、谁能看到什么

2.0 全站页面地图





外层包含关系就是权限关系：**Root** ⊃ **管理员** ⊃ **普通用户** ⊃ **访客**。

2.1 侧边栏菜单地图

分组	菜单项	路径	谁能看到
聊天	游乐场	/playground	所有登录用户
	聊天	/chat/...	所有用户（管理员配了预设才出现）
常规	概览	/dashboard/overview	所有用户
	数据看板	/dashboard/models	所有用户
	API 密钥	/keys	所有用户
	使用日志	/usage-logs/common	所有用户
	任务日志	/usage-logs/task	所有用户
个人	钱包	/wallet	所有用户
	个人资料	/profile	所有用户
管理员	渠道	/channels	管理员 + Root
	模型	/models/metadata	管理员 + Root
	用户	/users	管理员 + Root
	兑换码	/redemption-codes	管理员 + Root
	订阅	/subscriptions	管理员 + Root
	系统信息	/system-info	仅 Root
	任务插件	/task-plugins	仅 Root
	系统设置	/system-settings/...	管理员 + Root

公开页（不用登录也能看，取决于导航配置）： 首页 /、模型广场/价格 /pricing、排行榜 /rankings、关于 /about、用户协议、隐私政策。

2.2 顶栏元素

- 站点 Logo + 名称
- 顶部导航（大屏才显示，内容由"系统设置 → 站点与品牌 → 顶部导航"决定）
- 搜索按钮：快捷键 ⌘ K / Ctrl K，打开全局命令面板
- 铃铛（通知）：两个标签页，公告栏 + 公告列表
- 语言切换：中 / 英 / 繁中 / 法 / 俄 / 日 / 越
- 齿轮（配置抽屉）：主题、外观、侧边栏形态
- 头像（用户菜单）：个人资料 / 钱包 / 系统设置（仅 Root） / 登出


2.3 侧边栏能自定义


- 管理员全局改：系统设置 → 站点与品牌 → 侧边栏模块
- 用户自己改：个人资料 → 侧边栏模块卡片（Root 没有这个卡片）

进入"系统设置"后，侧边栏会整体切换成设置工作区，顶部有「← 返回控制台」。


第 3 章 接入多渠道大模型（渠道管理）

3.0 渠道页能干什么（功能全景）





3.1 五分钟接入第一个渠道（以 OpenAI 为例）



1. 侧边栏 → 渠道 → 右上角 创建渠道

2. 基本信息

- 类型 *：下拉选 OpenAI (可搜索)
- 名称 *：随便起个能认出来的名字，如 OpenAI-主号
- 已启用：保持打开

3. 身份验证

- API 地址：官方渠道留空。系统内置了官方地址。只有第三方中转站才填，且不要加 /v1，不要加结尾斜杠

- 添加模式：先选 单个密钥
- API 密钥 *：粘贴上游的 key

4. 模型

- 模型 *：点 从上游拉取（最省事），或点 填入相关模型 用预置列表；也能手打逗号分隔
- 分组 *：默认 default。这一步决定"哪些令牌能用到这个渠道"

5. 点 保存更改

6. 回到列表，点该行的仪表盘图标做一次测试 → 成功后「响应」列会出现响应时间

搞定。客户现在用 https://你的域名/v1 + 一个 sk- 令牌就能调了。

3.2 渠道列表每一列什么意思

列	含义
ID	渠道编号
名称	渠道名。名字旁边可能有小图标： ⚠️ 琥珀三角 = 开了「透传请求体」 📊 蓝色滑块 = 配了「参数覆盖」 🟢 +N / 🟡 -N = 检测到上游可新增/可移除 N 个模型，点它打开处理弹窗 名字下面的灰色小字是你填的备注
类型	上游厂商。多密钥渠道前面多一个图标：🔄 随机轮换 / 📅 轮询轮换
状态	已启用(绿) / 已禁用(红，你手动关的) / 自动禁用(黄，系统判定故障关的，鼠标悬浮看原因和时间) / 未知(灰)。多密钥渠道显示成 已启用 (可用数/总数)
模型	该渠道支持的模型（默认隐藏，用列显隐菜单打开）
分组	哪些用户分组能用到它
标签	你打的标签（默认隐藏）
优先级	越大越优先被选中。可以直接在格子里用上下箭头改，自动保存
权重	同优先级内做负载均衡，越大分到的请求越多
已使用 / 剩余	左 = 这个渠道累计消耗；右 = 上游剩余余额。点右边那个徽章会实时去上游查一次余额。余额 <1 红、<10 黄、≥100 正常。Codex 类型这里显示「账户信息」
响应	上次测试耗时：<500ms 优秀 / <1s 良好 / <2s 一般 / <5s 较差 / 从未测试
上次测试	相对时间（如"3 分钟前"），悬浮看完整时间
操作	见下

3.3 能对渠道做哪些操作

每行的按钮

-  编辑
-  测试连接（用默认测试模型快跑一次）
-  启用 / 禁用

每行「…」菜单

- 测试连接 — 打开完整测试弹窗（可逐个模型测）
- 查询余额

- 获取模型 — 从上游拉模型列表
- 上游更新 — 看上游新增/下线了哪些模型，可一键同步
- 管理 Ollama 模型 — 仅 Ollama
- 复制渠道
- 管理密钥 — 仅多密钥渠道，可按单个 key 启停/删除/看统计
- 删除（红色，需二次确认）

右上角的三个开关

- 批量操作 — 打开后出现勾选框和批量工具条
- 标签模式 — 同标签的渠道折叠成一行，可整组调优先级/权重/启停
- 使用 ID 排序 — 默认按优先级排，切成按 ID 排

右上角「更多」菜单（全局动作）

- 测试所有渠道
- 更新所有余额
- 检测所有上游更新 / 应用所有上游更新
- 修复渠道一致性 — 重建路由索引，重建期间路由可能短暂不完整
- 删除所有已禁用 — ⚠ 危险，会永久删除所有被禁用（手动+自动）的渠道

批量工具条（勾选后出现）

- 启用所选 / 禁用所选 / 为所选设置标签（输入框留空 = 移除标签） / 删除所选

说明：系统没有渠道导入/导出功能。最接近的是「复制渠道」和「复制全部模型名」。

3.4 筛选和搜索

- 主搜索框：按名称、ID 或密钥筛选
- 附加搜索框：按模型筛选
- 下拉筛选：状态（所有/已启用/已禁用）、类型（只列出当前实际存在的类型并带数量）、分组
- 点列头可排序：ID、名称、优先级、余额、响应时间、上次测试
- 工具栏最左的眼睛图标：一键把 ID / 名称 / 分组 / 额度打码成 · · · · ，方便截图分享

3.5 渠道表单完整字段说明

基本信息

字段	必填	默认	说明
类型 *	✔	OpenAI	上游厂商
任务插件 *	类型=任务插件时必填	—	选中插件会自动填入它声明的模型
名称 *	✔	—	例：OpenAI GPT-4 Production
已启用	—	开	新建时才显示
OpenAI 组织	—	空	仅 OpenAI，填 org-...

身份验证

字段	必填	说明
API 地址	通常选填；Azure / Custom / SunoAPI / 火山 / New API / 任务插件 必填	官方渠道留空。 不要带 /v1，不要带结尾斜杠
添加模式	—	单个密钥 / 批量添加（一行一个密钥）（生成多个渠道） / 多密钥模式（多个密钥，一个渠道）
API 密钥 *	☒	批量模式一行一个，并提供 去重 按钮。编辑时留空 = 保留原密钥
密钥更新模式	编辑多密钥渠道时出现	追加到现有密钥 / 替换全部现有密钥
多密钥策略	—	随机（每次随机取一个） / 轮询（  需要 Redis + 内存缓存，否则性能明显下降）

各厂商密钥格式速查

厂商	密钥格式
百度	APIKey SecretKey
讯飞	APPID APISecret APIKey
FastGPT	APIKey-AppId
腾讯	TokenHub API Key，或旧格式 AppId SecretId SecretKey
AWS	AccessKey SecretAccessKey Region（或 API Key 模式 APIKey Region）
Kling 可灵	AccessKey SecretKey（上游是 New API 时只填 ApiKey）
即梦	Access Key ID Secret Access Key
Codex	粘贴含 access_token / refresh_token / account_id 的 OAuth JSON

模型

字段	必填	说明
模型 *	☒	支持多选、手输自定义。快捷按钮：填入相关模型、填入所有模型、从上游拉取、复制全部、清空，还有 预设分组 一键填充
模型映射	—	JSON。把客户请求的模型名映射成上游真实模型名，如 {"gpt-4":"Azure-GPT4"}。左边是客户叫的名字，右边是实际转发的名字。有可视化编辑器
分组 *	☒	至少选一个。决定哪些分组的令牌能命中这个渠道

小贴士：做了模型映射后，**别把右边的上游真名也放进"模型"列表里**，否则 /v1/models 会暴露厂商内部名。系统会提示你「移除映射目标」。

高级设置 → 路由策略

字段	默认	说明
优先级	0	越高越先被选中，可负（最小 -999）
权重	0	同优先级内负载均衡权重，越高分到越多
测试模型	空	点"测试连接"时用哪个模型
自动封禁	开	连续失败自动禁用该渠道

高级设置 → 内部备注

- 标签：用于分组批量操作
- 备注：≤255 字，只有管理员能看到

高级设置 → 覆盖规则

字段	说明
状态码映射	把上游状态码改写成别的，如 {"400":"500"}。填高风险映射会弹风险提示
参数覆盖	JSON，覆盖请求参数（ 不能覆盖 stream ）。有可视化编辑器和"新格式模板"
请求头覆盖	JSON。支持变量 {api_key}（渠道密钥）、{client_header:名称}（客户端请求头）。有"填充模板"和"透传模板"按钮

高级设置 → 渠道额外设置

字段	默认	说明
强制格式化	关	强制把响应转成 OpenAI 标准（仅 OpenAI 类型）
思维到内容	关	把 reasoning_content 转成 content 里的 <think> 标签
透传请求体	关	请求体原样丢给上游，不做任何转换
跳过异步任务轮询延迟	关	轮询异步任务时不等 1 秒
代理地址	空	支持 http/https/socks5/socks5h，如 socks5://user:pass@host:port
HTTP 协议	自动	自动（可用时协商 HTTP/2） / HTTP/1.1（并发下强制多条 keep-alive 连接）
HTTP/2 连接分片	1	1-8，把流量分散到同一上游的多条连接上。选 HTTP/1.1 时不可用
系统提示词	空	该渠道的默认系统提示
系统提示词连接	关	把渠道系统提示与用户提示拼接

高级设置 → 字段透传控制（仅 OpenAI / Claude 系）

service_tier、store、safety_identifier、include（用量混淆）、inference_geo（地理路由 / Claude 数据驻留）、speed（Claude 推理速度）、anthropic-beta 请求头 —— 按需逐个打开。

高级设置 → 检测上游模型设置

字段	默认	说明
上游模型更新检查	关	定期检查上游模型变化
自动同步上游模型	关	检测到变化时自动更新模型列表（需先开上一项）
已忽略上游模型	空	逗号分隔精确名；加 regex: 前缀按正则忽略，如 gpt-4.1-nano,regex:^sora-.*\$
（只读）	—	上次检查时间、上次检测到可添加的模型

3.6 各厂商专属字段速查

厂商	需要额外填什么
Azure	AZURE_OPENAI_ENDPOINT *（如 https://xxx.openai.azure.com ）、默认 API 版本 *（如 2025-04-01-preview）、响应 API 版本（选填，空则用上面那个）
Custom（自定义）	完整 Base URL *，支持 {model} 变量。⚠️ 对接上游 One API / New API 请改用 OpenAI 类型
讯飞	模型版本 *，如 v2.1
OpenRouter	企业账户 开关
FastGPT	私有部署 URL，格式 https://fastgpt.run/api/openapi
AWS	AWS 密钥格式：AccessKey / SecretAccessKey 或 API Key
SunoAPI	API Base URL *（填 /suno 之前的路径，通常就是域名）
Cloudflare	账户 ID *
Vertex AI	Vertex AI 密钥格式（JSON / API Key）、服务账号 JSON 文件上传、部署区域 *（如 us-central1，或按模型分区的 JSON：{"default":"us-central1","claude-3-5-sonnet-20240620":"europe-west1"}）
火山方舟	API Base URL *：下拉选区域（北京 / 新加坡）
Coze	代理 ID *
Codex	密钥必须是 OAuth JSON；不支持批量创建；有免责声明必须阅读
高级自定义	高级自定义路由 配置器（点"配置路由"）
Dify	只支持 chatflow 和 agent，且 agent 不支持图片

3.7 渠道测试怎么看

快速测试：点行上的仪表盘图标，成功/失败会弹 toast，「响应」和「上次测试」两列立刻更新。

完整测试弹窗（「…」→ 测试连接）：

- 端点类型：自动检测 / OpenAI Chat / OpenAI Responses / Responses Compaction / Anthropic Messages / Gemini / Jina Rerank / 图片生成 / Embeddings
- 流式模式开关（embeddings、图片生成、rerank、responses 这几种下自动禁用）
- 中间是**模型表格**：模型 / 状态 / 结果 / 操作，可搜索过滤

- 测试全部 N 个模型：并发 5 个跑，有进度提示，可中途停止
- 结果里能看到成功的响应时间、失败的错误摘要（点开看完整错误）
- 两个实用动作：**勾选全部成功的模型**、**删除测试失败的模型**（确认后直接从渠道模型列表里移掉）

全局测试：右上角「更多」→ 测试所有渠道。测失败且开了自动封禁的渠道会变成"自动禁用"，鼠标悬浮能看到原因。

3.8 支持的渠道类型清单

OpenAI、Anthropic、AWS、Gemini、DeepSeek、Azure、Vertex AI、xAI、New API、高级自定义、任务插件、Mistral、Cohere、OpenRouter、Ollama、SiliconFlow、Perplexity、Moonshot、阿里通义、智谱 V4、智谱、百度、百度 V2、腾讯、讯飞、火山方舟、零一万物、MiniMax、Coze、360、Xinference、Dify、Jina、Cloudflare、Custom、ChatGPT 订阅(Codex)、Sub2API、FastGPT、MokaAI、MjProxy、MjProxyPlus、SunoAPI、Kling、即梦、Vidu、Submodel、豆包视频、Sora、Replicate、OhMyGPT。

3.9 多渠道是怎么挑的、挂了怎么切

这张图解释「优先级 / 权重 / 自动封禁 / 重试」四个字段合起来的效果。对应的全局开关都在 **系统设置 → 模型与路由 → 路由可靠性**（见 9.4）。

自动禁用条件（四者按配置生效）

渠道开了『自动封禁』


响应超过『禁用阈值（秒）』

状态码在『自动禁用状态码』里

错误消息含『失败关键词』

请求进来
模型 = gpt-4o, 令牌分组 = vip

筛出候选渠道：
状态=已启用 + 支持该模型
+ 声明了 vip



没有

有

报错：无可用渠道

取优先级最高的那一档

同档内按权重随机分配

发给上游

成功

失败


返回 + 结算



命中自动禁用条件

渠道变『自动禁用』
悬浮可看原因和时间

是



调优速查：

想达到的效果	怎么配
主用 A，A 挂了才用 B	A 优先级 10，B 优先级 0
A、B 三七分流量	两者优先级相同，权重 7 和 3
某渠道不稳定但不想它被自动关掉	关闭该渠道的 自动封禁
上游恢复后自动拉回来	开 定期渠道测试 + 成功后重新启用，模式选 仅检查被自动禁用的渠道
429 时自动换渠道而不是报错给客户	自动重试状态码 加 429，重试次数 设 2-3

第 4 章 模型与价格：怎么设置 Token 费用

4.1 先搞懂"倍率"和"美元"的换算（最关键的一条）

系统内部用**额度（quota）**记账，\$1 = 500,000 额度。

价格用**倍率（ratio）**表达，换算公式只有一条：

代码块

- 1 输入价（美元 / 每百万 token） = 模型倍率 × 2
- 2 输出价（美元 / 每百万 token） = 输入价 × 补全倍率

举例：

想要的价格	模型倍率	补全倍率
输入 \$2/M，输出 \$8/M	1	4
输入 \$0.5/M，输出 \$1.5/M	0.25	3
输入 \$30/M，输出 \$60/M	15	2

你不用自己算：编辑模型时可以把输入模式切成「价格模式（每百万 token 的美元价格）」，直接填美元数，系统自动反算倍率。

最终扣费公式：


代码块

1 费用 = 模型价格 × 分组倍率

（缓存 / 图像 / 音频等倍率都是在输入价基础上再乘一个系数，缓存倍率小于 1 就是打折。）

一次扣费到底按哪个价格算

三种定价方式可以共存，**优先级是固定的**，搞不清这个就会出现"明明改了倍率却没变"：



对不上账时的排查路径：使用日志 → 该条「详情」→ 计费详情，里面直接写了本次用的是哪种计费模式、输入/输出单价、分组倍率和总费用。

4.2 给单个模型定价（最常用）

路径：侧边栏 → 模型 → 找到模型点  编辑（或点 添加模型）→ 滚到 定价配置

定价配置第一层选 定价模式：

A. 按令牌计费（基于比例） — 绝大多数聊天模型用这个

- 第二层 输入模式 二选一：
 - **比例模式**：填 模型倍率 和 补全倍率，字段下方会实时告诉你"折算价格：\$X 每百万 token"
 - **价格模式（每百万 token 的美元价格）**：直接填 提示词价格 (\$/1M tokens) 和 完成价格 (\$/1M tokens)，下方实时显示折算出的倍率
- **高级选项（折叠）**：
 - 缓存倍率（缓存命中折扣，如 0.1）
 - 图像倍率
 - 音频倍率（音频输入）
 - 音频补全倍率（音频输出）

B. 按请求计费（固定价格） — 画图、视频等按次收费的

- 只有一个字段 固定价格 (USD)，如 0.01，表示**每次请求收多少美元，跟 token 数无关**
-  一旦设了按次价格，它的**优先级最高**，同名模型的各类倍率会被忽略

C. 动态/阶梯计费（表达式） — 高级玩法 入口不在这个抽屉里，在 **系统设置 → 计费与支付 → 模型定价 → 模型价格**，用可视化编辑器点进某个模型，把定价模式选为 Expression，然后用阶梯定价编辑器加档位（添加档位），支持可视化和原始表达式两种编辑方式。适合"按上下文长度分段计价""按 service_tier 分档"这类需求。

重要提示：**模型价格不存在模型这一行里**，它存在全站的价格表里。因此：

- 清空所有价格字段 = 删除这个模型的定价
- 改模型名会自动把旧名字的定价条目一起删掉
- 新建一个和已有定价同名的模型、且你没填任何价格时，不会覆盖已有定价

4.3 批量管理价格

路径：**系统设置 → 计费与支付 → 模型定价**，四个标签页：

标签页	用途
模型价格	全站价格表。可在「可视化 ↔ JSON」间切换。可视化模式按模型一行，顶部可按 按令牌 / 按次 / 表达式 筛选并显示各类数量。点行进入单模型定价抽屉。删除模型会同时清掉它在所有倍率表和表达式里的条目
未设置价格模型	列出还没配价的模型，方便补齐
工具价格	按 \$/1K 次 配工具调用单价。default 是默认价，其他键按模型前缀覆盖。 按请求计费的模型不额外收工具费
上游价格同步	选一个上游渠道，抓取并对比价格差异，可选择性同步过来

额外开关：暴露倍率接口 — 允许客户端通过 /api/ratio 查询你配置的倍率。

危险操作：**重置价格** — 会清除所有自定义定价并恢复上游默认值，有二次确认。


4.4 分组定价（不同客户不同价）

路径：**系统设置 → 计费与支付 → 分组定价**

字段	说明
分组比例	分组名 → 倍率。这是最常用的一项。例： { "default":1, "vip":0.8, "expensive":2 }
充值分组比例	按用户分组的 充值 价格乘数


可选分组	分组名 → 描述。 用户创建 API 密钥时能看到哪些分组，由这里决定
分组间覆盖	嵌套 JSON。外层=用户分组，内层=计费分组，用来覆盖跨分组的计费倍率
自动分配顺序	auto 分组从上到下依次尝试的分组数组
每个令牌的最大自定义分组数	令牌自定义 Auto 快照最多能选几个分组（默认 5）
默认使用自动分组	新建令牌默认落在第一个自动分组
特殊可用分组规则	用 +: 追加、 -: 屏蔽某些分组的可见性，有可视化编辑器

计价规则（背下来）：



常见误区：用户分组的基础倍率**不是个人折扣**。要给某人打折，是把他的令牌/账号放到一个低倍率的分组里。

三个 JSON 字段各管什么，别搞混：



4.5 模型管理页其他能力

模型列表列：ID、模型名称、**匹配类型**（精确/前缀/包含/后缀，非精确时显示命中数量并可悬浮看命中列表）、状态、供应商、描述、标签、端点、绑定渠道、启用分组、配额类型、官方同步、创建/更新时间。

新建/编辑模型的其他字段：

- 基本信息：模型名称 *、描述、图标（填 lobehub 图标 key，如 OpenAI）、供应商、标签
- 匹配规则：精确 / 前缀 / 包含 / 后缀
- 端点：可从模板下拉一键填入，JSON 编辑
- 状态与同步：启用、官方同步

批量操作（勾选后）：启用 / 禁用 / 复制模型名 / 删除。 **右上角「更多」**：缺失的模型（从缺失清单直接带名字去新建）、同步上游、预填充分组、管理供应商。 **部署页签**（/models/deployments）：需要先在系统设置里开 [io.net](#) 部署并测通连接。

4.6 客户怎么看价格（/pricing 模型广场）

表格列：模型、类型（计费模式徽章）、价格、缓存、供应商、标签、端点、分组。

用户查价姿势：先在工具栏选**自己的分组**和 **token 单位（1K / 1M）**，再看「价格」列的 输入价 / 输出价。点模型行会打开详情抽屉，里面有 API 调用示例、支持的应用、用量图表、性能与可用性、以及动态定价的分档明细。

工具栏还能按供应商 / 分组 / 计费类型 / 端点类型 / 标签筛选，切表格/卡片视图，切"是否按充值价显示"。

第 5 章 额度、分组与令牌（API Key）

5.1 全站额度规则怎么配

路径：**系统设置** → **计费与支付** → **额度设置**

字段	含义
新用户配额	新注册用户送多少额度
预消耗配额	每个请求发出前 先冻结 多少额度，结束后按实际用量结算差额。防止长请求超额
邀请者奖励	邀请人获得多少
受邀者奖励	被邀请人获得多少
免费模型预消耗	开启后，零成本模型也在结算前预扣
充值链接	外部购买额度的链接（如果你不用内置支付）
文档链接	你的文档站地址

每个数字框下方会实时显示 formatQuota 换算后的金额，不用心算。

 **邀请奖励填了非 0 值会报错**，除非你先去「计费与支付 → 支付网关」完成**合规条款确认**。这是硬性闸门，支付 / 兑换码 / 订阅读套餐 / 邀请奖励四个功能都被它锁着。

5.2 货币显示怎么配

路径：**系统设置 → 计费与支付 → 货币与展示**

字段	说明
显示模式	USD / CNY(元) / CUSTOM(自定义货币) / TOKENS(仅限 Token)。  TOKENS 是 单向的 ：切走之后这个选项就从下拉里消失，回不去了
每单位配额	每单位额度对应多少 token（默认 500000）。 只读 ，仅在特定条件下显示
美元汇率 / 人民币兑美元汇率	美元与支付网关货币的真实汇率
自定义货币符号	仅 CUSTOM 模式，如 ¥、HK\$，默认 ₭
每 USD 单位数	仅 CUSTOM 模式，如填 8 表示 1 USD = 8 个你的单位
以货币显示	只在当前为关闭状态时显示这个开关
显示 Token 统计信息	在界面里显示 token 用量统计

5.3 客户怎么建令牌（API Key）

路径：侧边栏 → **API 密钥** → 右上角 **创建 API 密钥**

基本信息

字段	默认	说明
名称	空	必填 。批量创建时，第 2 个起自动加 6 位随机后缀
分组	default（或 auto，取决于全站设置）	决定 计费倍率 和 可用渠道 。下拉里能看到分组名、描述和倍率
Auto 分组顺序	继承全局	仅当分组选 auto 时出现。拖拽排序，指定这个 key 依次尝试哪些分组。上限默认 5 个

跨分组重试	选 auto 时自动打开	当前分组的渠道全挂了，按顺序尝试下一个分组
过期时间	永不过期	日期时间选择器 + 4 个快捷按钮：永不 / 1 个月 / 1 天 / 1 小时
数量	1	仅新建时有 。一次批量创建多个（名字自动加随机后缀）。⚠️ 是逐个创建的，中途失败会停下，已建成的不回滚

额度设置

字段	默认	说明
无限配额	开	默认就是无限。 注意：无限只是不限这个 key，仍然受账户总余额约束
额度	10	关掉上面的开关才会出现。必须 ≥ 0


高级设置（默认折叠）

字段	默认	说明
模型限制	空 = 允许全部	多选，限制这个 key 只能调哪些模型
IP 白名单（支持 CIDR）	空 = 不限	每行一个，支持单 IP（203.0.113.10）和网段（10.0.0.0/8）。 ⚠️ 安全提示：IP 可被伪造，请配合 nginx / CDN 等网关使用，不要过度信任

点 保存更改 完成。

auto 分组 + 跨分组重试是怎么工作的

普通分组是"钉死在一个分组"，auto 是"按顺序挨个试"：



⚠ 注意：不同分组倍率不同，所以**同一个 auto 令牌不同请求的单价可能不一样**（取决于最终落在哪个分组）。日志的「令牌」列会显示本次实际用的分组和倍率。

5.4 令牌列表每一列什么意思

列	含义
名称	令牌名
状态	已启用 / 已禁用 / 已过期 / 已耗尽。非启用状态的整行会变淡
API 密钥	默认脱敏显示 sk- · · · · 。 点击文本 才会向后端取真实密钥并弹出可全选复制的输入框；右边有独立复制按钮
额度	显示成 剩余 / 总额 + 进度条。总额 = 已用 + 剩余（推算出来的，不是独立字段）。进度条 ≤10% 红、≤30% 橙、其余绿。悬浮看已用/剩余/总计三行。无限额度的显示 无限制 徽章，点开只能看已用量
分组	分组名 + 该分组倍率；auto 分组会体现跨分组重试
模型	未限制显示 无限制；否则显示 N 个模型，悬浮列出具体模型名
IP 限制	未限制显示 无限制；否则 N 个 IP，悬浮列出
创建时间	—
最后使用时间	超过 3 个月没用过会变成警告色
过期	永不过期显示 永不；已过期显示红色

5.5 令牌能做什么操作

行内按钮：🔌 启用/禁用（点了立即生效，无二次确认）、✏ 编辑

「…」菜单：

- 复制密钥 — 复制完整 sk-...
- 复制连接信息 — 把密钥 + 服务地址打包成一个连接串，方便粘贴到支持的客户端或别的 New API 渠道里
- CC Switch — 一键导入 CC Switch 客户端（见下）
- 聊天子菜单 — 管理员配了聊天预设才出现，点一下自动带着 key 跳到对应客户端
- 删除（红色）

批量操作（勾选后）：

- 复制选定的密钥 — 复制成"名称 + Tab + 密钥"的多行文本
- 删除选定的 API 密钥
- （没有批量启用/禁用、批量改分组）

CC Switch 导入弹窗：

- 应用：Claude / Codex / Gemini
- 名称：默认 My Claude / My Codex / My Gemini
- 模型：Claude 有 主模型 * + Haiku / Sonnet / Opus 模型（选填）；Codex/Gemini 只有 主模型 *
- 点 Open CC Switch 会拼出 ccs witch:// 深链并打开。**Codex 的 endpoint 是「服务地址 + /v1」，Claude / Gemini 直接用服务地址**

筛选：按名称搜、按 API 密钥搜、按状态筛选。

5.6 客户怎么用这个 key

代码块

```
1 curl https://你的域名/v1/chat/completions \  
2   -H "Content-Type: application/json" \  
3   -H "Authorization: Bearer sk-你的密钥" \  
4   -d '{"model": "gpt-4o", "messages": [{"role": "user", "content": "hi"}]}'
```

Claude 格式用 /v1/messages，Gemini 用 /v1beta/...，画图用 /v1/images/generations，Embeddings 用 /v1/embeddings。

5.7 令牌数量上限

路径：系统设置 → 安全与限制 → 令牌限制 → 每个用户的最大令牌数（默认 1000，设太大影响性能）。

第 6 章 用户与管理员权限

6.1 三种角色能干什么



包含关系即权限关系。另外两条特殊规则：

- **Root 是被保护对象**：不能被禁用、降级、删除、重置 Passkey、重置 2FA
- **Root 没有个人侧边栏自定义卡片**（管理员和普通用户有）

能力	普通用户 (1)	管理员 (10)	Root / 超级管理员 (100)
建 API Key、看自己用量、充值	✓	✓	✓
渠道、模型、用户、兑换码、订阅、系统设置	✗	✓	✓
系统信息、任务插件	✗	✗	✓
编辑其他管理员的 细粒度权限	✗	✗	✓
日志切换"查看全站 / 仅自己"	✗	✓	✓
日志详情里的 Root 诊断信息	✗	✗	✓

概览页/看板的"性能健康"面板	✖	✔	✔
用户菜单里的"系统设置"快捷入口	✖	✖	✔
个人资料里的"侧边栏模块"自定义	✔	✔（但开放不了系统设置子项）	✖（Root 没有这个卡片）

Root 受保护：不能被禁用、降级、删除、重置 Passkey、重置 2FA。

6.2 用户列表每一列什么意思

列	含义
ID	用户编号，可复制
用户名	有备注时旁边显示绿色徽章（悬浮看全文）；显示名与用户名不同时在下面显示小字
状态	已启用 / 已禁用 / 已注销。 悬浮 tooltip 里藏着「请求次数」（不是独立列！） 。已注销的行会灰化且没有任何操作按钮
额度	同时显示已用和剩余
分组	用户分组徽章
角色	用户 / 管理员 / Root（带图标）
邀请信息	三个徽章：已邀请: N、收入: X、邀请人: ID（没有邀请人时显示 无邀请人）
创建时间 / 最后登录	—

筛选：按用户名/名称/邮箱搜、状态、角色。可排序：ID、用户名、额度、分组、创建时间、最后登录。

⚠ 用户列表没有任何批量业务操作，勾选只能"清除选择"。

6.3 管理员能对用户做什么


右上角 添加用户。每行有 🖋 编辑 + 「…」菜单：

菜单项	说明
启用 / 禁用	互斥显示，点了立即生效。Root 不能被禁用
降级	仅目标是管理员且非 Root 时出现
提升	仅目标不是管理员时出现
管理绑定	帮用户解绑第三方账号
管理订阅	管理该用户的订阅
重置 Passkey	二次确认。用户之后要重新注册 Passkey 才能免密登录
重置 2FA	二次确认。用户必须重新设置两步验证
删除	红色，二次确认，不可撤销

改角色只能用「提升 / 降级」，编辑抽屉里没有角色下拉（只有新建时才能选角色）。

6.4 怎么给用户充/扣额度

入口不在「…」菜单里，在编辑抽屉内。很多人在菜单里找半天，路径是这样的：



1. 用户列表 → 点某行 编辑
2. 滚到 分组与配额 段
3. 剩余额度 是只读的，右边有 调整额度 按钮，点它
4. 弹窗里：
 - 顶部实时预览：当前额度 + 增量 = 结果
 - 模式 三选一：添加 / 减少 / 覆盖
 - 金额：添加/减少模式必须 > 0；覆盖模式可填任意值（含负数）
 - 回车即提交
5. 成功提示"额度调整成功"

6.5 编辑用户表单完整字段

基本信息

- 用户名：新建必填；编辑时禁用（用户名不可改）
- 角色：仅新建时出现，只有 普通用户 和 管理员 两个选项（不能设成 Root）
- 显示名称：留空则用用户名
- 密码：新建要求 8–20 字符；编辑时留空 = 不改密码

分组与配额（仅编辑）

- 分组
- 剩余额度（只读 + 调整额度按钮）
- 备注：管理员备注，只有管理员能看


管理员权限（仅 Root 能看到，且目标必须是管理员）

- 按「资源 → 动作」两级列出所有权限复选框，可覆盖默认管理员权限
- 底部会提示你自己是否具备"编辑敏感渠道设置"的权限
- 最典型的用途：给某个管理员关掉渠道的敏感写权限，让他能改模型/分组/优先级/权重，但看不到和改不了密钥。被限制的管理员打开渠道编辑抽屉时会看到"敏感渠道设置对您的账户为只读"

绑定信息（仅编辑，全部只读）GitHub ID、Discord ID、OIDC ID、WeChat ID、Email、Telegram ID。要解绑请用「…」→ 管理绑定。

第 7 章 收款：充值、兑换码、订阅套餐、签到

7.0 第一步：合规确认（不做这步下面全部锁着）



路径：系统设置 → 计费与支付 → 支付网关

页面顶部会显示红色告警「需要确认合规条款」：在 Root 确认之前，支付、兑换码、订阅套餐和邀请奖励功能保持锁定。

点「确认合规」→ 勾选 6 条声明 → 手工抄写确认文本（抄错会报错）→ 提交。成功后显示「合规已确认 · 用户 #ID 于 时间 确认」。

7.1 配在线支付

同一页面的 常规设置（所有网关共享）：

字段	说明
价格（本地货币/美元）	每 1 美元余额收多少钱（易支付用）
最低充值（美元）	—
付款方式	JSON 数组，也有可视化编辑器。例：[{"name":"支付宝","type":"alipay","icon":"SiAlipay"}]。 ⚠️ type 决定走哪个支付流程：stripe → Stripe，waffo_pancake → Waffo Pancake，其他值 → 易支付。配了 Stripe 密钥但没在这里加 type: stripe 的项，用户端看不到入口
充值金额选项	预设金额 JSON 数组
金额折扣	按金额的折扣映射 JSON

易支付网关

- 端点：如 <https://pay.example.com>
- 回调地址：只填站点根域名（如 <https://api.example.com>），不要带 /api/user/epay/notify 这类路径；留空则用「服务器地址」
- 易支付商户 ID、密钥（留空 = 保留原值）


Stripe

- 密钥（sk_xxx / rk_xxx）、Webhook secret（whsec_xxx）、Price ID（price_xxx）
- 单价、最低充值金额（美元）、促销代码 开关
- 页面上写明了要在 Stripe 后台配的 Webhook URL 和必需事件：checkout.session.completed、checkout.session.expired

Creem：API Key、Webhook Secret、测试模式、产品 JSON（有可视化编辑器） **Waffo / Waffo Pancake**：分别有独立字段块，Pancake 保存前**必须同时选好或新建店铺和产品**

密码类字段（各种 Secret / Key） **留空 = 不修改**，只有填了新值才会覆盖。

客户充值时到底发生了什么



排查充值不到账：**使用日志 → 筛选类型『充值』 → 点详情 → 充值审计信息**（订单支付方式、回调支付方式、回调来源 IP、服务器 IP）。回调没来 = 网关那侧的 Webhook URL 或回调地址配错了。

7.2 兑换码

路径：侧边栏 → **兑换码**

列表列：ID、名称、状态（未使用/已使用/已禁用，过期时优先显示黄色 已过期）、兑换码（掩码显示前 8 位 + **** + 后 8 位，可展开看全码、可复制）、额度、创建、过期（0 显示 永不过期）、兑换者（User {id}，悬浮看用户 ID 和兑换时间）。

新建表单：

字段	说明
名称	1-20 字符。 新建时留空会自动用额度金额做名字
额度	数字，单位随全站货币设置
过期时间	选择器 + 快捷按钮 永不 / 1M(1 个月) / 1W(7 天) / 1 Day。留空 = 永不过期

数量	仅新建可见，1-100，一次批量生成
----	--------------------

生成后成功提示「Successfully created N redemption codes」，回列表逐个复制发给客户即可。

7.3 订阅套餐

路径：侧边栏 → 订阅

页面常驻提示：Stripe / Creem 需要先在第三方平台创建商品再把 ID 填进来。合规未确认时创建/修改被锁。

列表列：ID、计划（标题+副标题）、价格、有效期、额度重置、优先级、状态、支付渠道（Stripe / Creem / Waffo Pancake 徽章）、计划额度（0 显示 无限）、升级分组（无则 No Upgrade）。

新建/编辑表单四段：

① 基本信息

字段	说明
计划标题 / 计划副标题	如"基础版" / "适合轻量使用"
计划价格	用户购买要付多少， 实际币种取决于支付网关
额度	计划包含的总额度，每个计费周期可用， 0 表示无限
升级分组	买了之后把用户升到哪个分组（分组承载了可用模型和倍率， 权限和限流是靠分组间接实现的 ）
降级分组	到期后降到哪个分组，默认"降级回购买前分组"
购买限制	每人最多买几次，0 = 不限
排序	展示顺序
启用状态	开关
允许用余额兑换	开关
额度用尽后允许用钱包余额	开关

② **有效期设置：**有效期单位（选 custom 时改填 自定义秒数）+ 有效期数值 ③ **额度重置：**重置周期（选 custom 时可填 自定义秒数） ④ **第三方支付配置：**Stripe Price ID（price_...）、Creem Product ID（prod_...）、Waffo Pancake Product ID（下拉选已有商品，或点右边 + Create 用当前标题和价格自动建一个）

7.4 签到奖励

路径：系统设置 → 计费与支付 → 签到奖励

- 启用签到功能：允许用户每日签到领随机额度
- 开了之后才显示 签到最小额度（如 1000）和 签到最大额度（如 10000）

开启后，用户在 **个人资料** 页会看到「签到日历」卡片（开了 Turnstile 的话会带人机校验）。








7.5 邀请奖励


- 金额在 **计费与支付 → 额度设置** 的 邀请者奖励 / 受邀者奖励 里配（需先完成合规确认）
- 用户在 **钱包** 页看到「推荐计划」卡片：待转入（aff_quota）、累计（历史总收入）、邀请人数，可复制邀请链接
- 有待转入奖励时出现 **转入余额** 按钮
- 注册页会自动读取链接里的 ?aff=xxx 作为邀请码

第 8 章 监控台字段字典（看板 + 日志）

这一章就是你要的"每个字段代表什么"。

8.0 我想看某个东西，该去哪个页面





8.1 概览页 /dashboard/overview

顶部「开始使用」引导（不是统计数据）

三步清单，自动判断完成状态：创建 API 密钥 → 充值 → 发送请求。右侧给一段可复制的 curl 示例，还有三个信号灯：Route active（路由是否在线）、Auth configured（是否已有密钥）、Model selected（示例用的模型）。可折叠，折叠后显示 Setup progress: 完成数/总数。

「用量概览」三张卡

卡片	含义	时间范围
近 24 小时消耗	最近 24 小时消耗的额度总和	滚动近 24 小时，按小时聚合
历史使用情况	账号累计总消耗	全部历史
请求计数	账号累计总请求数	全部历史

每张卡带 12 段迷你折线。

「剩余额度」面板

字段	含义
主数值	当前余额
健康状态点	正常 / 余额偏低（按当前速率预计不足 3 天） / 余额已耗尽（余额 ≤ 0）
Last 24h usage	近 24 小时消耗
Runway（可用时长）	余额 ÷ 近 24 小时消耗，单位天。<1 天显示"剩余不足 1 天", >999 显示 999+ 天，无消耗显示"暂无使用记录"。这是接近 24 小时速率线性外推的估算，不是精确预测

注意：迷你折线里的余额曲线是用当前余额倒推的近似值，只看趋势，不是历史真实余额。

「性能健康」面板（仅管理员）

数据源固定为最近 24 小时，不跟随任何筛选器。

指标	含义	显示格式
成功率	各模型成功率的简单算术平均（⚠️ 不按请求量加权，一个低流量的故障模型会明显拉低整体数字）	99.50%。100% 深绿 / ≥90% 浅绿 / ≥70% 琥珀 / <70% 红

平均延迟	各模型平均总延迟的简单平均	<1s 显示 123ms，≥1s 显示 1.23s，无数据 —
吞吐量	各模型平均输出速度的简单平均	12.3 t/s，≥1000 显示 1.2K t/s
流量最高的模型	前 6 个模型 + 各自成功率色点	—

如果显示"暂无性能数据"：说明这个时间窗内没采集到指标 —— 新部署、没流量，或者性能指标采集被关了（系统设置 → 运维 → 监控与警报 → 启用模型性能指标）。

其余面板（后台开了才出现）

API 信息、系统公告、常见问答、Uptime Kuma 可用性。四个都在「系统设置 → 控制台内容」里各自有开关。

8.2 数据看板 /dashboard/models（模型调用分析）

顶部 5 个统计格

格子	含义
总数	所选时间范围内的请求条数总和
总额度	所选时间范围内消耗的额度总和
总 Token 数	所选时间范围内 token 总和
平均 RPM	总请求数 ÷ 所选时间范围的分钟数（是平均值，不是瞬时 RPM）
平均 TPM	总 token ÷ 所选时间范围的分钟数

数字太长会压缩显示，鼠标悬浮看完整值。

「性能健康」内联条（仅管理员）

和概览页同一份数据，固定 24 小时窗口，不跟随页面筛选。

图表

1. 额度分布 — 标题右侧显示总计额度。可切「柱状图 / 面积图」。横轴 = 时间桶（按所选粒度：小时/天/周），纵轴 = 消耗额度，按模型堆叠（模型太多时非 Top 模型归入 Other）
2. 模型调用分析 — 标题右侧显示总调用次数。三个标签页：
 - 调用趋势：折线，横轴时间桶，纵轴调用次数，按模型分系列
 - 调用次数分布：饼图，扇区 = 各模型占比
 - 调用次数排行：条形图，按调用次数降序

筛选器（右上角「筛选」按钮）

区块	字段	说明
快速范围	1 天 / 7 天 / 14 天 / 29 天	选了会自动联动粒度：≤1 天→小时，≥29 天→周，其余→天
自定义	起始时间 / 结束时间	手选后快速范围取消高亮
图表设置	时间粒度	小时 / 天 / 周
仅限管理员	用户名	只有管理员能看到，按用户名过滤

右上角还有「图表偏好」按钮，可以把默认图表类型、默认时间范围和粒度存下来。

⚠️ 澄清一个常见误解：这个页面**没有按模型/渠道/分组/令牌的明细筛选，也没有明细表格**。要看明细请去「使用日志」。

另外两个看板

- /dashboard/flow（**分流**）： 流量流向图，带"隐藏/显示敏感数据"眼睛开关和节点筛选
- /dashboard/users（**用户统计，仅管理员**）： 用户消耗排行 + 用户消耗趋势，筛选项有时间粒度、快速范围、Top N（默认 10）

8.3 使用日志 /usage-logs/common

顶部两个关键控件

- 视图范围 Tabs（仅管理员）**：全部 / 仅自己。⚠️ 切到"仅自己"后，**所有管理员专属列会一起消失**，等于退回普通用户视角
- 眼睛图标**：把用户名/令牌名/分组/渠道名打码成 · · · · ·，连筛选输入框都会变成密码样式

统计条（跟随当前筛选）

徽章	含义
用量	当前筛选条件下的额度消耗总额
RPM	后端统计的每分钟请求数
TPM	后端统计的每分钟 token 数

注意：这里的 RPM/TPM 和数据看板那两个"平均 RPM/TPM"**算法不同**，别混着比。

表格每一列什么意思

列	含义
时间	上行：完整时间戳。下行： 日志类型徽章
渠道（仅管理员）	#渠道ID 徽章 + 渠道名。附加标记： · 多密钥渠道显示用了第几个 key · 🔄 分支图标 = 发生过重试，点开看 重试链路 ch1 → ch2 → ch3 · ✨ 闪光图标 = 命中了渠道亲和性，点开看规则和分组
用户（仅管理员）	头像 + 用户名， 点击打开用户信息弹窗
令牌	密钥名徽章。下面一行是 分组 + 分组倍率 （如 vip 1.5x）。有专属倍率时优先显示专属倍率
模型	模型徽章。发生模型重定向时同时显示实际上游模型
流	上行：流 / 非流 / 异步。流式且状态异常时带红色告警图标（悬浮看结束原因和软错误数）。下行： TPS （输出 token ÷ 耗时），无数据显示 —
Tokens	主行 输入 / 输出。有缓存时副行显示 缓存 ↓ 读取数 和 ↑ 写入数。都为 0 显示 -
费用	本条实际扣费（含违规扣费等特殊标记）
耗时	流式显示两行：首字（FRT，首个 token 到达时间）+ 耗时（总时长）；非流式只显示耗时。左侧色条按快慢着色（绿/黄/红），首字缺失显示 不适用
详情	一行计费摘要，多条时右侧带 +N。 点击打开日志详情弹窗

「详情」列摘要能看到什么（按情况显示）：

- 管理员优先片段：红色 额度已钳制、Plugin: 名称 @ 版本
- 管理/登录类日志：本地化的操作描述
- 退款：异步任务退款
- 消耗类：
 - 违规扣费 → 红色 违规扣费 + 违规代码 + 扣费: 金额
 - 动态计费 → 命中档位标签 · 输入价/输出价/M，另加 缓存 价格
 - 按次计费 → 每次调用 · 价格
 - 标准按 token → 标准 · 输入价/输出价/M
 - 都没配价 → 分组倍率 1.5x 或 专属倍率 x
 - 命中系统提示覆盖 → 红色 系统提示覆盖

哪些列会是空的：只有 未知/消耗/错误/退款 这四类日志才有渠道、令牌、模型、Tokens、费用；只有 消耗/错误 才有流和耗时。
充值、管理、系统、登录类日志这些列本来就是空的。

筛选条件

主排：时间范围（快速预设 24 小时 / 7 天 / 14 天 / 30 天）、模型名称、分组、日志类型 高级（展开，右上角带激活数量角标）：
令牌名称、用户名（仅管理员）、渠道 ID（仅管理员）、请求 ID、上游请求 ID

所有输入框回车即应用；筛选条件会写进 URL，可以直接分享或收藏。

日志类型枚举

类型	中文	颜色
0	未知	灰
1	充值	青
2	消耗	绿
3	管理	橙
4	系统	紫
5	错误	红
6	退款	蓝
7	登录	蓝绿

⚠ 一个既有的小别扭：下拉里的「所有类型」在后端就是 type=0，而列表里 type=0 又显示为「未知」。这是后端把 0 当作"全部"哨兵值造成的，知道就好。

8.4 日志详情弹窗字段字典

点「详情」列打开，只显示有数据的分区。

概要区

字段	说明
请求 ID / 上游请求 ID	排查问题时给上游客服看这个
渠道（仅管理员）	ID (名称)

重试链路（仅管理员）	ch1 → ch2
令牌 / 分组	—
IP 地址	消耗/错误类日志的 IP 对日志所有者也可见；充值类日志的 IP 仅管理员可见
响应时间	总耗时；流式还会追加 (FRT: x.xs)

其他分区

分区	出现条件	主要字段
请求转换	仅管理员	路径、转换链（a -> b -> c，单段显示"原生格式"）
额度已钳制	仅管理员	类型（溢出/下溢/无效 NaN）、原始值、钳制为、操作。表示"额度饱和保护已触发"
拒绝原因	仅管理员	红色文本块
违规扣费	有违规	违规代码、违规标记、扣费金额
退款详情	退款类	任务 ID、原因
任务插件	仅管理员	插件 key / 名称 / 版本 / 作者
Root 诊断	仅超管	API 版本、插件世代、上游任务 ID、节点名称
充值审计信息	充值类 + 管理员	订单支付方式、回调支付方式、回调来源 IP、服务器 IP、节点名称、系统版本
操作管理员 / 操作审计信息	管理类 + 管理员	操作人、认证方式（访问令牌/会话）、变更了哪些字段、请求方法与路由、结果（成功 200 / 失败 4xx）
登录信息	登录类（ 本人也可见 ）	操作、登录方式、IP 地址、User Agent
语音 Token	有音频	语音输入/输出、文字输入/输出
推理强度	有 reasoning_effort	徽章（low/medium/high）
系统提示词	被覆盖时	徽章「已覆盖」
模型映射	发生映射时	请求模型 / 实际模型
Token 明细	有 token	输入 Token、输出 Token、缓存读取、缓存写入、缓存写入 (5m)、缓存写入 (1h)、图像 Token
计费详情	消耗类	计费模式（动态计费/每次调用/按 Token）、命中档位、输入价、输出价、分组倍率或专属倍率、各类缓存单价、音频输入/输出单价、图片输入单价、网页搜索（Nx (单价)）、文件搜索、图片生成、 计费路径（仅管理员）、用量参数、总费用
动态计费	表达式计费	完整分档定价明细表（弹窗会自动加宽）
计费路径	管理员	本地计费（蓝色显示器图标，本地按 token 算）/ 上游返回（绿色云图标，直接用上游报的 usage）

流状态	流式异常	状态、结束原因、软错误数、结束错误、错误列表
订阅计费	用订阅结算的	套餐、实例、预扣费、结算差额、最终消耗、剩余 已用/总量
参数覆盖	有覆盖	每条"动作 + 内容"
内容	有内容	原始内容文本， 错误日志的具体错误信息通常在这里

8.5 任务日志 /usage-logs/task

列	含义
提交时间	上行提交时间，下行结束时间（未结束显示 -）
渠道（仅管理员）	—
用户（仅管理员）	头像 + 名称，点开看用户信息
插件（仅管理员）	插件名称 / key @ 版本 / 作者链接
任务 ID	可复制。副行显示 平台 · 任务动作。平台：suno / sunoapi / kling / runway / luma / viggles；动作：生成音乐 / 生成歌词 / 图生视频 / 文生视频 / 首尾帧生视频 / 参照生视频 / 视频 Remix
耗时	结束时间 — 提交时间。 超过 300 秒进入警告色
状态	成功 / 未开始 / 排队中 / 进行中 / 失败 / 未知
进度	进度条
制品	生成结果预览（图/音/视频）
详情	「查看详情」按钮 → 任务详情弹窗；有失败原因时下方红字截断显示

任务详情弹窗：

- 基本信息：任务 ID、平台、动作、进度、提交/开始/结束时间、原始模型、实际模型、失败原因
- 仅限管理员：用户、渠道、分组、额度、请求 ID、请求路径、任务插件
- Root 诊断（仅超管）：API 版本、插件世代、上游任务 ID、节点名称

8.6 绘图日志 /usage-logs/drawing（MidJourney 类）

列	含义
提交时间	上行时间，下行 状态徽章
渠道（仅管理员）	—
类型	绘图 / 放大 / 视频 / 编辑 / 变换 / 强变换 / 弱变换 / 平移 / 图生文 / 混合 / 上传 / 缩词 / 重绘 / 局部重绘 / 换脸 / 缩放 / 自定义缩放
任务 ID	可复制
耗时	—
提交结果（仅管理员）	已提交 / 等待中 / 重复 / 未提交


进度	—
图片	「查看」按钮打开图片弹窗
提示	截断显示，点开看完整提示（含英文提示）
失败原因	截断显示，点开看完整错误

任务/绘图日志的筛选比通用日志简单：只有时间范围、任务 ID、渠道 ID（仅管理员），没有日志类型和统计条。

8.7 「用户信息」弹窗（管理员点用户名时弹出）

用户名、显示名称、余额、已用额度、请求计数、用户分组、邀请码、邀请人数、邀请额度、备注。

8.8 怎么"接入监控"



系统没有 Prometheus 导出，也没有 webhook 告警。可用的监控手段是这四条：


1. **内置性能指标**：系统设置 → 运维 → 监控与警报 → 启用模型性能指标（默认开）。数据展示在概览页/数据看板的"性能健康"面板和模型广场的模型卡片上
2. **额度告警邮件**：系统设置 → 运维 → 监控与警报 → 配额提醒（token）。用户余额低于此值时发邮件（**依赖 SMTP 配好**）
3. **用户自建通知**：用户在个人资料里可以选邮件 / Webhook / Bark / Gotify 四种方式接收余额预警
4. **接入外部状态页**：系统设置 → 控制台内容 → Uptime Kuma，把你的 Uptime Kuma 状态页嵌进概览页


另外「系统设置 → 运维 → 性能」里有个**性能监控面板**（只读统计 + 运维动作），能看磁盘缓存命中、内存占用、GC 次数等，并可开启"系统资源超阈值时拒绝新请求"的保护。

第 9 章 系统设置全清单（7 大类）

9.0 系统设置总览与保存规则

40 多个分区都挂在 7 个大类下，每个分区一个独立 URL（/system-settings/<大类>/<分区>）：





保存规则（改任何设置前先看这四条）

- 每个分区都是**独立的 URL**：/system-settings/<大类>/<分区>，可以直接收藏
- **只提交你改过的字段**（差异保存）。什么都没改就点保存会提示"没有需要保存的更改"
- **所有密码类字段留空 = 保留原值**（SMTP 密码、易支付密钥、Stripe 秘钥、Turnstile Secret、各 OAuth Client Secret、Worker 访问密钥……）
- 有未保存改动时切换页面会被拦截提醒

9.1 站点与品牌（Site & Branding）

系统信息

字段	说明
系统名称 *	全站显示的名称，必填
服务器地址	你的对外 URL。 OAuth 回调、Webhook、外部集成全靠它 ，务必填对
异步任务对外地址	异步任务生成的媒体文件用哪个域名对外。留空则回退到服务器地址。必须是绝对 HTTP(S) URL，不能带认证信息/查询串/锚点
徽标 URL	站点 Logo 图片地址
页脚	页面底部文本
关于	支持直接写 HTML，或填一个完整 URL（会以 iframe 嵌入）
首页内容	支持 Markdown。填 URL → iframe 嵌入自定义首页；填 HTML → 隔离渲染；填 Markdown/纯文本 → 直接渲染；留空 → 使用内置默认落地页
用户协议	支持 Markdown / HTML / URL。 留空 = 关闭协议勾选要求
隐私政策	同上

系统公告

公告内容 —— 登录后的全局弹窗通知。（和"控制台内容 → 公告"是两套东西，那边是控制台里的公告列表）

顶部导航

勾选要在顶栏显示哪些入口：主页、控制台、文档、关于、模型广场。模型广场还有子开关 **要求登录才能查看模型**。


侧边栏模块

控制管理端侧边栏各模块/子项的显隐，有「恢复默认」按钮。

9.2 身份验证（Authentication）

基本身份验证

字段	说明
密码登录	允许用密码登录
注册已启用	是否允许新用户注册（总闸）
密码注册	允许用密码注册
电子邮件验证	新账户需邮箱验证。 依赖运维 → SMTP 邮箱配好，否则发不出验证码
电子邮件域限制	只允许特定邮箱域



电子邮件别名限制	阻止 <code>user+alias@domain.com</code> 这种写法	系统维护
电子邮件域白名单	每行一个域名。只在上面的域限制开关打开时才生效	

OAuth 集成（6 个标签页）

每个标签页顶部都有「设置指南」卡片，展示你要粘到第三方后台的 Homepage URL / 回调 URL，并有复制按钮。**服务器地址没配好这里会显示占位符。**

- **GitHub**：启用 GitHub OAuth、Client ID、Client Secret
- **Discord**：启用、Client ID、Client Secret
- **OIDC**：启用 OIDC、OIDC 显示名称（留空默认显示 "OIDC"）、Client ID、Client Secret、Well-Known URL（必须以 http(s) 开头，填好后可点按钮**自动发现端点**）、以及三个可选覆盖项：授权端点 / Token 端点 / 用户信息端点
- **Telegram**：启用、Bot Token、Bot Name
- **LinuxDO**：启用、Client ID、Client Secret、最低信任等级
- **微信**：启用、微信服务器地址、Server Token、公众号二维码图片地址

Passkey 认证

字段	说明
启用 Passkey	允许用 Passkey(WebAuthn) 注册和登录
依赖方显示名称	Passkey 弹窗里展示给用户的名字
依赖方 ID	必须等于当前域名或其父域 ，如 <code>example.com</code>
用户验证	必需 / 推荐 / 不推荐（是否要求生物识别/PIN）
设备类型偏好	无限制 / 内置设备（指纹、面容、Windows Hello） / 外部设备（USB 安全密钥）
允许不安全来源	允许非 HTTPS 注册 Passkey， 仅开发环境用
允许的 Origins	每行一个，如 <code>https://example.com</code>

机器人保护

启用 Turnstile、站点密钥、密钥。**⚠️** 开了开关但没填 Key 会导致登录页人机验证失效。

自定义 OAuth

列表式增删改，添加你自己的 OAuth 提供商。页面顶部展示回调 URL 格式并可复制。

2FA（两步验证）没有系统级开关，它是用户在个人资料里自行绑定的能力。

9.3 计费与支付（Billing & Payment）

6 个分区：额度设置、货币与展示、模型定价、分组定价、支付网关、签到奖励。👉 详见 第 4 章、第 5 章、第 7 章。

9.4 模型与路由（Models & Routing）

全局模型配置

字段	说明
启用请求透传	请求直接转发给上游，不做任何后处理

不自动处理思考后缀的模型	JSON 数组。命中的模型不自动增删 -thinking/-nothinking 后缀，也豁免 @ 修饰符解析。条目以 re: 开头表示正则，如 re:.*@sha256.*
ChatCompletions → 响应兼容	JSON 对象。 ⚠️ 预览/实验性功能 ，格式和行为可能变。有"填充示例"按钮
保持连接心跳	定期发 ping 帧保持流式连接
Ping 间隔（秒）	建议设大一些以避免上游限流

路由可靠性（很重要，故障切换全在这里）

请求重试

- 重试次数：失败请求重试几次（0–10）
- 自动重试状态码：逗号分隔，支持区间，如 401, 403, 429, 500-599。下方会显示归一化结果

渠道健康检查

- 定期渠道测试：后台自动探测所有渠道
- 渠道测试模式 三选一：
 - 主动检查全部渠道 — 定时检查除手动禁用外的全部渠道
 - 主动检查已开启自动禁用的渠道 — 只检查开了自动禁用的
 - 仅检查被自动禁用的渠道 — 不打扰正常渠道，只复查被自动禁用的，恢复后重新启用
- 测试间隔(分钟)：≥1
- 渠道测试并发数：1–32
- 成功后重新启用：测通了就自动恢复启用

自动禁用规则

- 失败时禁用：总开关
- 禁用阈值（秒）：响应时间超过就自动禁用
- 自动禁用状态码：同样支持逗号+区间
- 失败关键词：每行一个。上游错误消息里包含任一关键词（不区分大小写）就自动禁用该渠道

Gemini

安全设置（按类别覆盖，default 兜底）、版本覆盖（模型 → API 版本）、支持的 Imagine 模型、思考后缀适配器 + 预算令牌比例（0.002–1，预算 token = max tokens × 比例）、启用 FunctionCall 思维签名填充、移除 functionResponse.id 字段（Vertex AI 不支持这个字段）。

提示：即使关掉思考后缀适配器，Gemini 仍会自动检测思考模式；只有需要更精细的定价/预算控制时才开。

Claude

请求头覆盖（按模型覆盖 header，可用于开启扩展上下文等 beta 特性）、默认最大 Token 数、思考后缀适配器 + 预算令牌比例（0.1–1）。

Grok

启用违规扣费（默认开）、违规扣费金额（默认 0.05，说明：基础金额，实际扣费 = 基础金额 × 系统分组倍率）。

渠道亲和性

让同一个会话优先复用上次成功的渠道（对 Codex CLI / Claude CLI 这类多轮工具很有用）。

字段	说明
启用	总开关

最大条目数	内存缓存上限
默认 TTL（秒）	亲和记录多久过期
成功后切换亲和	亲和渠道挂了、重试到别的渠道成功后，把亲和更新到新渠道
渠道禁用后保留亲和	关闭时会删掉这条记录并重新选渠道
规则 JSON	必须是数组。有可视化/JSON 双模式

规则表列：名称 / 模型正则 / Key 来源 / TTL / 重试 / 作用域 / 缓存条目 / 操作。运维按钮：刷新缓存、清空全部缓存（二次确认）、单条规则清空缓存、**填充 Codex CLI / Claude CLI 模板**（一键追加两条现成规则）。

模型部署

启用 [io.net](#) 部署、[io.net](#) API 密钥 + **测试连接**按钮。页面里有获取密钥的三步指引（打开 [io.net](#) 控制台的 API Keys 页 → 创建/选择密钥时把项目设为 io.cloud → 复制粘贴）。

9.5 安全与限制（Security & Limits）

速率限制

 页面明确提示：**这里只控制模型请求的速率限制。Web/API 路由的限流由环境变量配置，仍可能返回 429。**

字段	说明
启用速率限制	总开关
限制周期	时间窗口，单位分钟
每周期最大请求数	0–100000000。包括失败请求，0 = 无限制
最大成功请求数	1–100000000，只统计成功的
基于分组的速率限制	JSON，格式 {"default":[200,100],"vip":[0,1000]}，即 [最大请求数, 最大成功数]。分组配置覆盖全局限制，但共用同一个周期。有可视化编辑器

敏感词

启用过滤（检测到敏感词就拦下消息）、检查用户提示（提示在到达上游前被扫描）、已阻止的关键词（每行一个，**留空则禁用列表但保留开关状态**）。

SSRF 保护

防止服务器被诱导去请求内网地址。

字段	说明
启用 SSRF 保护	总开关
允许私有 IP	允许请求 10./172.16./192.168. 等内网段
域名过滤模式	黑名单（阻止列出的域） / 白名单（只允许列出的域）
域名白/黑名单	每行一个域名
IP 过滤模式	黑名单 / 白名单
IP 白/黑名单	每行一个 IP 或 CIDR
允许的端口	逗号分隔，如 80,443,8080。 留空 = 所有端口

对已解析的域应用 IP 筛选器	即使按域名访问，也对解析出的 IP 做过滤
-----------------	-----------------------

令牌限制

每个用户的最大令牌数（≥1，默认 1000）。

9.6 控制台内容（Console Content）

后 4 个分区（公告 / API 地址 / 常见问题 / Uptime Kuma）用同一套交互：顶部一个 已启用 开关（立即保存），下面一个表格。
表格里的增删改只改本地草稿，必须点「保存设置」才生效（每次操作都会提示你点保存）。都支持多选批量删除，也都能切换到 JSON 直接编辑。

数据仪表盘

启用数据仪表盘、刷新闻隔(分钟)（1-1440，**保持大于 1 分钟以避免数据库压力过大**）、默认时间粒度（小时/天/周，提示：只是 UI 粒度，数据仍按小时汇总）。

公告

单条字段：内容（≤**500 字符，支持 Markdown 和 HTML**）、发布日期、类型、额外备注（≤100 字符）。

API 地址

单条字段：API URL、路由（如 CN2 GIA）、说明信息（如"推荐给中国大陆用户"）、徽章颜色。这些会显示在概览页的"API 信息"面板，方便客户挑线路。

常见问题

单条字段：问题（≤200 字符）、答案（≤1000 字符，支持 Markdown / HTML）。

Uptime Kuma

单条字段：分类名称（≤50 字符，如"核心 API、OpenAI、Claude"）、Uptime Kuma URL、状态页面 Slug（≤100 字符，**只能用字母数字连字符下划线**）。最终会拼成 <URL>/status/<slug>。

聊天预设（客户端接入配置）

存的是一个 JSON 数组，**每一项必须是只含一个键值对的对象**：{"客户端名":"URL"}。有可视化和 JSON 两种编辑模式。

示例：

代码块

```
1  [
2    {"ChatGPT": "https://chat.openai.com"},
3    {"Lobe Chat": "https://chat-preview.lobehub.com/?settings={...}"}
4  ]
```

URL 里可以用这些占位符（这是配置的精髓）：

占位符	会被替换成
{address}	你的站点地址（URL 编码后）
{key}	用户的一个 已启用 令牌（自动补 sk- 前缀）
{cherryConfig}	Cherry Studio 的配置包（base64）
{aionuiConfig}	AionUI 的配置包
{deepchatConfig}	DeepChat 的配置包

{aqbotConfig}	AQBot 的查询串
---------------	------------

三种链接类型自动识别：

- 以 http(s):// 开头 → **web 类型**，站内 iframe 打开
- 以 fluent 开头 → **fluent 类型**，走浏览器扩展，侧边栏里不显示
- 其他（如 cherrystudio://...）→ **自定义协议**，点击唤起本地客户端

⚠ 注意：/chat/{id} 里的 id 就是数组下标，重排 JSON 会让老链接指向别的客户端。

绘图

6 个开关：

字段	说明
启用绘制功能	MidJourney 风格图像生成的 总开关
允许上游回调	接受上游回调（⚠ 会泄露服务器 IP ）
允许 accountFilter 参数	需要为不同上游账户代理请求时保持开启
将回调 URL 重写到本地服务器	自动把上游回调 URL 换成你的服务器地址
在提示中清除模式标志	移除 --fast、--relax、--turbo 等参数
在后续操作前要求任务成功	必须等绘图成功才能放大/变体

9.7 运维（Operations）

系统行为

默认折叠侧边栏（对新用户生效）、演示站点模式、自用模式（优化为单人自托管场景，会隐藏定价类入口）。

监控与警报

字段	默认	说明
配额提醒（token）	—	用户额度低于此值时 发邮件告警 （依赖 SMTP）
启用模型性能指标	开	采集延迟与成功率，供模型广场和性能面板展示
刷库间隔（分钟）	5	关掉指标时该字段禁用
聚合时间桶	1 小时	1 分钟 / 5 分钟 / 1 小时
保留天数	0	0 表示永久保留

SMTP 邮箱（邮箱验证、找回密码、额度告警的前置依赖）

字段	说明
SMTP 主机	如 smtp.example.com

端口	常用 25 / 465 / 587
SMTP 加密方式	单选三选一：无加密 / SSL/TLS / STARTTLS
跳过 SMTP TLS 证书验证	允许自签名或主机名不匹配的证书
强制 AUTH LOGIN	强制用 AUTH LOGIN 方式认证
用户名	认证账户
发件地址	如 New API <noreply@example.com>
密码 / 访问令牌	留空 = 保留现有凭证

Worker 代理

Worker URL（必须以 http(s) 开头，**结尾斜杠会自动去掉**）、Worker 访问密钥（留空保留原值）、允许 HTTP 图像请求。

日志维护

- 1. **记录配额使用量** — 这就是"请求日志"总开关。提示：跟踪每个请求的消耗以支持用量分析，**保持开启会增加数据库写入**
- 2. **清理历史日志**（数据库）：选一个时间戳 → 点「清理日志」→ 二次确认「这将永久删除该时间之前创建的所有日志条目，此操作无法撤销」。清理是**异步后台任务**，页面会显示"日志清理进度：已处理 X / Y 条"
- 3. **服务器日志管理**（磁盘日志文件）：只读显示 日志目录 / 日志文件数 / 日志总大小 / 时间范围。清理方式二选一：保留最近 N 个文件 或 保留最近 N 天，点「清理日志文件」二次确认，完成后提示清理了几个、释放了多少空间。（没配日志目录时显示"服务器日志功能未启用"）

性能

磁盘缓存设置（大请求体临时落盘而不占内存，建议 SSD 环境用）

字段	默认
启用磁盘缓存	关
磁盘缓存阈值 (MB)	10
磁盘缓存最大总量 (MB)	1024
缓存目录	空（用系统临时目录）

页面会显示磁盘可用/总空间，**可用空间小于配置的最大缓存量时会弹警告。**

系统性能监控（开启后，系统资源超阈值时新请求会被拒绝） 启用监控（默认关）、CPU 阈值 (%) 90、内存阈值 (%) 90、磁盘阈值 (%) 95。





性能监控面板（只读 + 运维动作） 分区展示：请求体磁盘缓存（活跃文件、磁盘命中）、请求体内存缓存（当前缓存大小、活跃缓存数、内存命中）、缓存目录磁盘空间、系统内存统计（已分配、累计分配、系统内存、GC 次数）、缓存目录信息。按钮：刷新统计、清理未活跃缓存（删除 10 分钟未使用的临时文件）、重置统计、执行 GC。

系统维护

纯只读 + 一个动作：显示 当前版本 和 启动时间，点 **检查更新** 去 GitHub 查最新 Release。已是最新会提示"您正在运行最新版本"，有新版会显示版本号 and 发布详情。

注：**Redis 不在这里配**，它由环境变量 REDIS_CONN_STRING 决定。


9.8 跨分区依赖清单（最容易踩的坑）




	付款方式 JSON 里的 type	warro_pancake → 正 Waffo Pancake
你想做的事	必须先做什么	
邮箱注册/验证、找回密码、额度告警邮件	配好 运维 → SMTP 邮箱	其他值 → 走易支付
任何 OAuth 登录、支付回调	填对 站点与品牌 → 系统信息 → 服务器地址	
邀请奖励、在线支付、兑换码、订阅套餐	完成 计费与支付 → 支付网关 → 合规确认 身份验证 电子邮件域限制 开关	电子邮件域白名单才生效
邮箱域白名单生效	打开 电子邮件域限制 开关	
用户端看到 Stripe 支付入口	在 付款方式 JSON 里加一项 type: stripe 安全与限制 启用过滤 开关	已阻止的关键词才生效
敏感词列表生效	打开 启用过滤 开关	
io.net 部署页可用	在 模型与路由 → 模型部署 开启并测通连接	
异步任务媒体走独立域名	填 异步任务对外地址 (留空回退服务器地址) 模型与路由 → 模型部署 启用 io.net + 测通连接	/models/deployments 页可用

第 10 章 用户自助中心（个人资料 / 钱包 / 游乐场 / 聊天）使用日志有数据

10.0 客户能自己搞定哪些事





10.1 登录、注册、找回密码

登录页 /sign-in 的元素都是条件显示的，取决于你在后台开了什么：

- 用户名或电子邮件 + 密码（开了密码登录才有），密码框右上角有「忘记密码？」
- Turnstile 人机验证（开了才显示）
- 使用 Passkey 登录 按钮（设备不支持时按钮禁用并提示）
- 第三方登录（分隔线"或继续使用"下面）：微信 → GitHub → Discord → OIDC（按钮文案用你配的显示名）→ LinuxDO → Telegram → 任意数量的自定义 OAuth
- 微信登录弹窗：显示你配的公众号二维码，说明"扫码关注公众号并回复『验证码』获取验证码"，输入验证码后确认
- 法律条款勾选：配了用户协议或隐私政策时必须勾选，不勾选所有登录入口都会提示"请先同意法律条款"
- 开了 2FA 的账号，登录后会跳到 两步验证 页输入验证码

Passkey 免密登录

两步验证 2FA + 备用码

系统访问令牌（只显示一次）

注册页 /sign-up：用户名 → 密码（8-20 字符）→ 确认密码 → （开了邮箱验证才有）电子邮件 + 验证码 + 「发送验证码」按钮（发送后倒计时）→ Turnstile → 法律条款 → 创建账户。下面同样有整套第三方注册按钮。链接里带 ?aff=xxx 会自动作为邀请码提交。

通知方式：邮件 / Webhook / Bark / Gotify

忘记密码 /forgot-password：只填 Email → 「发送重置邮件」（有倒计时防重复）→ 收邮件点链接完成改密。

10.2 个人资料 /profile

顶部资料头

头像、显示名、角色徽章、用户 ID（点击复制）、@用户名、邮箱、分组。下面三格统计：

- 当前余额（剩余额度）
- 总用量（累计消耗）
- API 请求（累计请求数）

签到（后台开了才有）

语言、登录会话、侧边栏模块

设置卡 → 账户绑定

只显示你在后台开启了的方式：邮箱、微信、GitHub、Discord、OIDC、Telegram、LinuxDO。每张卡显示图标、名称、已绑定绿徽章、绑定值或"未绑定"。

删除账户

⚠ 除邮箱可以「更改」外，已绑定的内置方式在个人页不能自助解绑（要么找管理员用「管理绑定」，要么它是自定义 OAuth）。自定义 OAuth 区的已绑定项有红色解绑按钮 + 确认框。

设置卡 → 设置与偏好

/playground 试模型通不通

字段	说明
通知方式	四选一：邮件 / webhook / bark / gotify
配额警告阈值	余额低于该值时通知
（邮件模式）通知邮箱	留空使用账户邮箱
（webhook 模式）Webhook 地址 + Webhook 密钥	—
（bark 模式）Bark 推送 URL	支持模板变量 {{title}}、{{content}}
（gotify 模式）Gotify 服务器 URL + 应用 Token + 消息优先级（0-10，默认 5）	页面附三步设置说明和官网链接

/usage-logs 查自己的用量与报错

/pricing 查模型价格

/dashboard/overview 查余额可用天数

自助排查

偏好设置区三个开关：

- 接收上游模型更新通知（**仅管理员可见**）— 定时检查发现上游模型变化或检查失败时发汇总通知
- 接受未定价模型 — 允许使用没配价格的模型
- 记录 IP 地址 — 用量和错误日志里记 IP

安全卡

三个方块：

- **更改密码** — 当前密码 / 新密码（≥8 位） / 确认新密码。新密码不能与旧密码相同
- **访问令牌** — 这是**系统访问令牌**（用于管理类 API，不是调模型的 sk-）。**⚠ 只显示一次**，现有令牌无法再查看；点「重新生成」会先二次确认，**新令牌一生成旧的立即失效**，用旧令牌的脚本会停止工作
- **删除账户**（红色）— 必须**原样输入自己的用户名**才能启用删除按钮，成功后自动登出

Passkey 登录卡

状态行显示 启用/禁用 徽章、备份状态、最后使用 时间。未启用时按钮是 **启用 Passkey**，设备不支持会禁用并提示换支持生物识别/安全密钥的设备。已启用时是 **解绑 Passkey**（先确认，再走 2FA 或 Passkey 本身做安全校验）。

两步验证卡

状态行显示 启用/禁用（被锁时额外显示 Locked），已启用时显示 剩余备用码数量。未启用 → **启用**；已启用 → **重新生成备用代码 / 禁用 2FA**（红色）。

其余卡片

- **语言偏好**
- **登录会话** — 查看和注销登录会话
- **签到日历** — 只有后台开了签到才出现（开了 Turnstile 会带人机校验）
- **侧边栏模块** — 自定义自己的侧边栏显示哪些模块（Root 没有这个卡片）

10.3 钱包 /wallet

统计卡

当前余额（剩余额度）、总用量（累计消耗）、API 请求（累计请求数）。

添加资金（充值）

右上角有 **订单历史** 按钮。

在线支付步骤：

1. 点一个**预设金额**格子（每格显示额度数值、折扣标签、Pay 实付金额，有折扣时还显示 · Save 省下的钱），或在 **自定义金额** 里填数字（不能低于最低充值额）
2. 右侧实时显示 **应付金额**
3. 点选 **支付方式**（某方式的最低充值高于当前金额时会禁用并提示）
4. 弹出**支付确认对话框**，核对额度 / 实付 / 支付方式 / 折扣 / 汇率
5. 确认后跳转支付。成功后页面自动刷新余额

兑换码步骤：同一张卡下方的兑换码输入框粘贴兑换码 → 点 **兑换额度** → 成功后输入框清空、余额刷新。

如果站点配了外部 充值链接，这里还会有一个外链入口。

订阅计划卡

展示可购买的订阅套餐（没有可用计划时整块隐藏，充值卡占满宽度）。

推荐计划卡（邀请奖励）

三格统计 待转入 / 累计 / 邀请人数，邀请链接只读框 + 复制按钮。有待转入奖励时出现 **转入余额** 按钮（合规未确认时禁用并提示）。

10.4 游乐场 /playground（自测渠道通不通）

布局：上方对话区（空态有推荐提示词），下方输入区。

输入区底部工具条：

-  附加、 搜索（ **目前这两个按钮只是弹一条说明提示，还没有真的上传/联网能力**）
-  参数面板
-  清空聊天历史（二次确认，清空的是浏览器本地保存的消息）
- 右侧：**模型 + 分组选择器 + 发送**（生成中变成红色 **停止**）

参数面板（桌面是浮层，手机是底部抽屉）。标题「参数设置」，副标题「只有启用的参数会随请求发送」——**每个参数都有独立开关，关掉的参数不会发给上游**。这是最容易踩的坑：很多"参数不生效"就是因为开关没打开。

参数	控件	范围	默认值	默认是否启用
温度 Temperature	滑块	0.1-1	0.7	
Top P	滑块	0.1-1	1	
频率惩罚	滑块	-2-2	0	
存在惩罚	滑块	-2-2	0	
最大 Tokens	数字	0-200000	4096	 默认关
随机种子 Seed	数字	0-2147483647	未设置	 默认关

没有系统提示输入框，也没有思考模式开关——思考模式在本项目里是通过**模型名后缀**实现的（如 gemini-2.5-flash-thinking、claude-3-7-sonnet-20250219-thinking、-low / -medium / -high），所以做法是在**模型选择器里选带后缀的模型名**。

用它测渠道：

1. 选一个**分组**（分组决定命中哪些渠道和倍率）和**目标模型**
2. 发一句 hi
3. 有流式回复 → 该分组下这个模型的链路是通的；失败会以错误消息形态出现在对话里
4. 报错排查顺序：把 最大 Tokens 关掉或调小、把频率/存在惩罚和 seed 关掉（部分上游不支持这些参数会直接报错）→ 再试 → 然后去「使用日志」和「渠道」页看具体错误

单条消息可以复制 / 重新生成 / 编辑 / 删除；编辑后可以"仅保存"或"保存并重新提交"。所有消息和参数都存在浏览器本地。

10.5 聊天 /chat（接第三方客户端）

这不是内置聊天界面，而是**把第三方客户端接进来的机制**：

- **web 类型**预设 → 站内 iframe 打开
- **自定义协议**预设 → 点击唤起本地客户端（直接访问 /chat/{id} 会提示"从侧边栏触发"）
- 侧边栏的「聊天」是个动态聚合项，列出所有非 fluent 预设。**一个可见预设都没有时这个菜单项整体不显示**
- /chat2link 是快捷跳转页：自动取第一个 web 预设 + 一个可用令牌，直接跳走。没有 web 预设会提示"No available Web chat links"，没有可用令牌会跳回 /keys

管理员配置位置：**系统设置 → 控制台内容 → 聊天预设**（见 9.6）。

10.6 其他公开页

- **首页 /**: 内容由「首页内容」决定（URL → iframe / HTML → 隔离渲染 / Markdown → 渲染 / 留空 → 内置落地页：Hero + 站点统计 + 特性 + 使用流程 + CTA + 页脚）
- **模型广场 /pricing**: 见 4.6
- **排行榜 /rankings**: 时间范围可切 today / week / month / year（默认 week，写进 URL 的 ?period=）。三个分区：模型榜（含趋势图）、厂商份额、涨跌榜（上升/下降）
- **关于 /about**: 同样是 URL / HTML / Markdown / 留空四种形态；留空时显示内置空态和项目信息

10.7 任务插件与系统信息（仅 Root）

任务插件 /task-plugins

- 标题右侧是全局开关 启用任务插件。 关掉会让整个任务插件系统停服（含工厂插件），关闭时会弹危险确认，列出所有受影响插件的"N 个渠道，M 个进行中任务"
- 两个标签页：已安装（可上传插件、点行看详情、对某个 key 重新上传）和 市场（浏览、安装、管理来源）
- 工厂插件不能单独删除或禁用，但可以用自定义版本覆盖；删除/禁用覆盖版本会恢复工厂插件

系统信息 /system-info: 两块面板 —— 实例信息、系统任务。


第 11 章 常见问题速查表

现象	去哪里看 / 怎么修
客户报 401	令牌是否已禁用/过期/耗尽（API 密钥页状态列）；多机部署 SESSION_SECRET 是否一致
客户报"模型不存在"	渠道的 模型 列表里有没有这个名字；渠道 分组 和令牌 分组 是否匹配
客户报"无可用渠道"	渠道是否被自动禁用（状态列悬浮看原因）；分组 是否对上
渠道老是自动禁用	系统设置 → 模型与路由 → 路由可靠性：调 禁用阈值、自动禁用状态码、失败关键词；或直接关掉该渠道的 自动封禁
上游好了但渠道还是禁用	开 成功后重新启用 + 定期渠道测试，或用 仅检查被自动禁用的渠道 模式
扣费不对	使用日志 → 点该条「详情」→ 看 计费详情（计费模式、输入/输出价、分组倍率、总费用）和 计费路径（本地算 vs 上游报）
明明设了倍率却不生效	检查这个模型有没有设 按次固定价格 —— 按次价格优先级最高，会让倍率全部失效
想给某客户打折	建一个低 分组比例 的分组，把他的令牌/账号放进去。 改用户分组的基础倍率不等于个人折扣
发不出验证码/邮件	系统设置 → 运维 → SMTP 邮箱，检查主机/端口/加密方式/密码
OAuth 回调 404	系统设置 → 站点与品牌 → 系统信息 → 服务器地址 填对了吗
支付/兑换码/订阅都点不了	系统设置 → 计费与支付 → 支付网关，完成 合规确认
用户端看不到 Stripe 入口	付款方式 JSON 里加一项 type: stripe
概览页显示"暂无性能数据"	该时间窗没采到指标：新部署 / 无流量 / 系统设置 → 运维 → 监控与警报里 启用模型性能指标 被关了
数据看板没数据	系统设置 → 控制台内容 → 数据仪表板，启用数据仪表板 打开了吗

日志一片空白	系统设置 → 运维 → 日志维护，记录配额使用量 打开了吗
数据库越来越大	系统设置 → 运维 → 日志维护 → 清理历史日志；性能指标 保留天数 别设 0
Playground 参数不生效	参数面板里每个参数的 独立开关 是否打开
想让思考模型思考	在模型名后加 -thinking / -low / -medium / -high 后缀
想把响应时间打上去	渠道 优先级 调高 + 权重 调整；开 HTTP/2 连接分片；给渠道配就近的 代理地址
想让多轮工具会话固定走一条渠道	系统设置 → 模型与路由 → 渠道亲和性，开启并用「填充 Codex CLI / Claude CLI 模板」
截图怕泄露信息	渠道页/日志页工具栏的 眼睛图标 ，一键打码

附录 A 新站上线检查清单

上线全流程一图流



按顺序打勾，全打完就能对外了。

基础

- ☐ Docker 起来了，-v ./data:/data 挂载数据目录
- ☐ 配了 TZ、SESSION_SECRET；生产环境配了 SQL_DSN (MySQL/PG) 和 REDIS_CONN_STRING
- ☐ HTTPS 已就绪，配了 SESSION_COOKIE_SECURE=true + SESSION_COOKIE_TRUSTED_URL
- ☐ 走完 /setup 向导，或用 root/123456 登录后立刻改了密码

站点身份

- ☐ 系统设置 → 站点与品牌 → 系统信息：填了系统名称和服务器地址
- ☐ 填了页脚、关于、首页内容（可选）
- ☐ 需要用户协议/隐私政策的话填上（留空就是不要求勾选）

渠道

- ☐ 至少一个渠道，测试通过，「响应」列有数字
- ☐ 渠道的模型和分组配对
- ☐ 有多个同类渠道时，设好了优先级和权重
- ☐ 系统设置 → 模型与路由 → 路由可靠性：重试次数、自动重试状态码、定期渠道测试、成功后重新启用 都配了

价格

- ☐ 系统设置 → 计费与支付 → 模型定价 → 未设置价格模型 标签页是空的（没有漏配价的模型）
- ☐ 系统设置 → 计费与支付 → 分组定价：配好了分组比例和可选分组
- ☐ 系统设置 → 计费与支付 → 货币与展示：选好了显示模式和美元汇率
- ☐ 用 /pricing 页面自己核对了几个模型的价格是否符合预期

账号与收款

- ☐ 系统设置 → 身份验证：注册已启用 / 密码注册 / 电子邮件验证 按需配置
- ☐ 配好了 SMTP，且实际收到过一封验证邮件
- ☐ 开了 Turnstile（对外站强烈建议）
- ☐ 完成了 合规确认
- ☐ 配好了支付网关，付款方式 JSON 里的 type 和网关对得上，实际跑通了一笔小额充值
- ☐ 系统设置 → 计费与支付 → 额度设置：新用户配额、预消耗配额、邀请奖励都配了

安全

- ☐ 系统设置 → 安全与限制 → 速率限制：开了并设了合理的周期和上限
- ☐ SSRF 保护开了
- ☐ 每个用户的最大令牌数 设了合理值
- ☐ 给协作管理员用 Root 权限矩阵关掉了渠道敏感写权限（防止密钥外泄）

运维

- ☐ 系统设置 → 运维 → 日志维护：记录配额使用量 开了
- ☐ 系统设置 → 运维 → 监控与警报：启用模型性能指标 开了，配额提醒 设了阈值，保留天数 不是 0
- ☐ 系统设置 → 控制台内容：数据仪表板 开了，配了 API 地址、公告、常见问答
- ☐ 数据库有自动备份
- ☐ 规划了日志清理节奏（数据库日志 + 磁盘日志文件）

本指南只覆盖网页操作。更完整的部署、环境变量和 API 细节见 [官方文档](#)。